基于 KMNIST 数据集的手写字符分类

王浦丞　　吴羽迪

2026 年 1 月 5 日

1　问题背景

历史文献的保存与可访问性，是技术创新与文化遗产保护交叉领域的一项关键挑战。在日本，这一挑战的典型代表是已使用逾千年的古日本草书——崩し字（Kuzushiji）。自明治维新（1868 年）日语标准化以来，日本公民识读崩し字的能力急剧衰退。如今，仅少数母语者能够辨读 [1]。尽管大规模数字化项目已建立了这些文献的图像档案，但自动且准确地识别这种文字仍是亟待解决的问题。

为使用机器学习方法应对这一挑战，Clanuwat 等学者 [2] 推出了崩し字-MNIST（KMNIST）数据集作为基准数据集，同时提供了更丰富的崩し字-49 和崩し字-汉字数据集。KMNIST 数据集的数据分布与经典的 MNIST 数据集相同，但由于古日本草书的复杂性————变体假名（Hentaigana）的存在使得不同的古日本草书手写体可能对应同一个类别————它比 MNIST 的分类难度更大。此外，规模更大的两个数据集中，不同类别的数据数目可能相差甚远，反映了历史文献中字符的自然出现频率，为模型泛化带来了额外挑战。

早期使用卷积神经网络（CNN）和 ResNet 架构的基准实验已证明该数据集的可行性，同时也显示出其性能与 MNIST 存在差距，印证了其更高的难度 [2]。后续基于此数据集的分类多使用深度学习方法，传统机器学习模型在该数据集上的表现仍缺乏探索。本项目评估了多种经典机器学习算法——包括多层感知机（MLP）、支持向量机（SVM）、随机森林和 k-近邻算法（k-NN）——以及基础 CNN 模型在 KMNIST 数据集上的性能。

我们的对比分析表明，即使没有现代深度学习模型的复杂结构，这些经典方法也能在这个手写字符识别的任务上取得相当好的结果。这一发现不

仅为理解 KMINST 数据集的特性与难度提供了更广阔的视角，也为计算资源受限的场景提供了参考。

2 Kuzushiji-MNIST 数据集

Kuzushiji-MNIST 是一个由历史日文草书字符图像构成的数据集。它包含一个由 60000 个样本组成的训练集和一个由 10000 个样本组成的测试集。在这两个子集中，代表 10 个类别的样本数量均相等。每个样本都是一张 28x28 像素的灰度图像，并带有来自 10 个类别的崩し字平假名字符标签。这十个字符如图1所示。该数据集旨在作为原始 MNIST 数据集的直接

index	0	1	2	3	4	5	6	7	8	9
codepoint	U+304A	U+304D	U+3059	U+3064	U+306A	U+306F	U+307E	U+3084	U+308C	U+3092
char	お	き	す	つ	な	は	ま	や	れ	を

图 1: 十个类别对应的字符标签

替代品，用于对机器学习算法进行基准测试，其图像尺寸及训练/测试集划分方式与 MNIST 保持一致。

数据集中的特征向量 $X \in \mathbb{R}^{784}$, 代表了图像中所有像素的灰度强度。数据集的部分示例如图2所示。请注意，训练集与测试集的划分比例分别为每个类别的 $\frac{6}{7}$ 和 $\frac{1}{7}$。每个像素的强度由一个介于 0 到 255 之间的整数值表示，我们已将其归一化到 [0,1] 区间。输出 $y \in \{0, 1, \ldots, 9\}$ 代表相应的类别标签。

该数据集的一个独特挑战源于其书写体系的历史特性：每个标签字符拥有多种被称为” 变体假名” 的有效书写形式，即单个标签字符可以有多种视觉上迥异、源自不同源汉字的写法。这一特性可以在图3中得到体现。这导致每个类别内形成了多模态分布和非线性的决策边界。因此，依赖线性可分性的方法可能需要非线性特征变换或核方法才能获得令人满意的性能。

Hiragana	Unicode	Samples	Sample Images
あ (a)	U+3042	7000	
い (i)	U+3044	7000	
う (u)	U+3046	7000	
え (e)	U+3048	903	
お (o)	U+304A	7000	
か (ka)	U+304B	7000	
き (ki)	U+304D	7000	
く (ku)	U+304F	7000	
け (ke)	U+3051	5481	
こ (ko)	U+3053	7000	
さ (sa)	U+3055	7000	
し (shi)	U+3057	7000	
す (su)	U+3059	7000	
せ (se)	U+305B	4843	
そ (so)	U+305D	4496	
た (ta)	U+305F	7000	
ち (chi)	U+3061	2983	
つ (tsu)	U+3064	7000	
て (te)	U+3066	7000	
と (to)	U+3068	7000	
な (na)	U+306A	7000	
に (ni)	U+306B	7000	
ぬ (nu)	U+306C	2399	
ね (ne)	U+306D	2850	
の (no)	U+306E	7000	

Hiragana	Unicode	Samples	Samples Images
は (ha)	U+306F	7000	
ひ (hi)	U+3072	5968	
ふ (fu)	U+3075	7000	
へ (he)	U+3078	7000	
ほ (ho)	U+307B	2317	
ま (ma)	U+307E	7000	
み (mi)	U+307F	3558	
む (mu)	U+3080	1998	
め (me)	U+3081	3946	
も (mo)	U+3082	7000	
や (ya)	U+3084	7000	
ゆ (yu)	U+3086	1858	
よ (yo)	U+3088	7000	
ら (ra)	U+3089	7000	
り (ri)	U+308A	7000	
る (ru)	U+308B	7000	
れ (re)	U+308C	7000	
ろ (ro)	U+308D	2487	
わ (wa)	U+308F	2787	
ゐ (i)	U+3090	485	
ゑ (e)	U+3091	456	
を (wo)	U+3092	7000	
ん (n)	U+3093	7000	
ゝ (iteration mark)	U+309D	4097	

图 2: Kuzushiji-49 数据集的样本示例



图 3: 同一标签拥有多种书写方式

3 算法与性能评估

在本节中，我们将介绍在本项目中使用的算法，以及用于评估模型性能的各种参数。

3.1 算法介绍

3.1.1 k 近邻算法

一种基础的分类算法是 k 近邻算法（k-Nearest Neighbors, kNN）。其核心思想非常简单：对于待分类的样本点，在训练集中找到与其距离最近的 k 个样本，确定这些样本的标签，然后进行投票，选择得票最多的类别作为该样本点的分类结果。

具体而言，令 $y(x)$ 表示样本 x 的标签，$N_k(x_0)$ 为 x_0 的 k 个最近邻样本，$w(x, x_0)$ 为 x 在 x_0 处的权重，则 kNN 算法可表示为：

$$\hat{y}(x_0) = \arg\max_j \sum_{x \in N_k(x_0)} w(x, x_0)\, 1_{\{y(x)=j\}}.$$

在标准的 kNN 算法中，所有最近邻样本被赋予相等的权重，即 $w(x, x_0) = 1$。然而，这种方法产生的分类边界可能是不连续的，当 k 值较小时会形成复杂的决策区域。此外，为距离较远的数据点赋予较低的权重更为合理。因此，也可以采用权重函数 $w(x, x_0) = \psi(\|x - x_0\|)$，其中 $\psi(\cdot)$ 是一个单调递减函数。在本项目中，我们使用 $\psi(x) = x^{-1}$。

3.1.2 降维与支持向量机

支持向量机（Support Vector Machine，SVM）是一种广泛用于分类和回归任务的监督学习算法。SVM 通过在高维空间中寻找一个最优分离超平面 $w^T x + b$ 来进行分类，该超平面能够最大化不同类别数据点之间的间隔。SVM 的主要优势在于能够处理高维数据并具有良好的泛化能力。

标准 SVM 模型引入了正则化参数 C 来平衡分类误差的最小化与决策间隔的最大化。其优化问题可表述为：

$$\begin{aligned} &\frac{1}{2}\|w\|^2 + C\sum_{i=1}^{N} \xi_i \\ &y_i\left(w^T x_i + b\right) \geq 1 - \xi_i, \quad i = 1, 2, \cdots, N \end{aligned}$$

其中，$w^T x + b$ 定义了用于分类的超平面，松弛变量 ξ_i 用于衡量数据集被超平面错误分类的程度。

正则化参数 C 控制着最小化训练误差与最大化分类间隔之间的权衡。当 C 值较大时，分类错误的惩罚更高，模型在训练集上的准确率更高，但分类间隔较小且对噪声更敏感。较小的 C 值则更强调间隔最大化，从而提高泛化能力，但可能导致欠拟合。

将 SVM 应用于高维数据时计算成本较高，因此通常与降维技术结合使用。在本项目中，由于每个样本对应于一个 724 维向量，维数较高，我们采用主成分分析（PCA）进行降维，只保留前 50 个主成分。此外，为处理非线性边界，我们采用高斯核函数进行数据映射。高斯核函数定义为：

$$K_\gamma(x_1, x_2) = e^{-\gamma \|x_1 - x_2\|^2}$$

其中，γ 是决定核带宽的参数，称为核带宽。

3.1.3 多层感知机

多层感知机（Multilayer Perceptron, MLP）是一种经典的前馈神经网络，广泛用于分类问题。MLP 由多个层组成，每层包含权重矩阵 W_i、偏置向量 b_i 以及非线性激活函数 σ。一个 L 层 MLP 的映射关系可描述为：

$$h_{l+1} = \sigma(W_l h_l + b_l)$$

其中 h_l 表示第 l 层的神经元值，$h_0 = X$ 为输入，$h_L = y$ 为输出。在分类任务中，通常对最后一层应用 Softmax 激活函数，将神经元输出转换为类别概率。

在训练过程中，MLP 使用反向传播算法结合梯度下降来最小化目标损失函数（如交叉熵损失），从而提高分类准确率。

MLP 的主要优势在于其能够处理高维数据并建模复杂的非线性关系，适用于多种分类任务。然而，深层且宽度较大的 MLP 容易出现过拟合，因此需要仔细设计网络结构。

在针对 KMNIST 数据集的实现中，我们使用的多层感知机的结构如下：

- **网络架构**：包含 3 个隐藏层，神经元数量分别为 512、256 和 128
- **激活函数**：使用 ReLU 激活函数

- **优化器**：采用 Adam 优化算法
- **正则化**：
  - L2 正则化系数：0.0001
  - 早停策略：当验证集损失连续 5 个迭代未改善时停止训练
- **训练配置**：
  - 批量大小：64
  - 最大迭代次数：20
  - 初始学习率：0.001，采用自适应学习率调整策略
  - 验证集比例：10%
- **数据预处理**：在 MLP 模型前使用标准归一化（StandardScaler）对输入特征进行标准化处理

该 MLP 模型通过逐步减少隐藏层神经元数量（512→256→128）构建了一个深而窄的网络结构，结合多种正则化技术以防止过拟合，从而在保持模型表达能力的同时增强泛化性能。

3.1.4 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是一种专门设计用于处理具有网格结构数据（如图像）的深度学习模型。其核心思想是通过卷积层自动提取输入数据的局部特征（如边缘、纹理），并利用池化层逐步降低特征图的空间尺寸，从而实现对平移、缩放等变换的一定程度的不变性。经过多个卷积-池化块的堆叠，网络能够学习到从低级到高级的、层次化的特征表示。最后，通过全连接层将这些高级特征进行整合，完成分类或回归任务。CNN 因其参数共享和局部连接的特性，相比全连接网络参数更少，效率更高。

在针对 KMNIST 数据集的实现中，我们使用的卷积神经网络的结构如下（或如图4所示）：

- **输入层**：接收 28×28 的图像数据。
- **第一卷积块**：

  - 包含两个卷积层，均使用 32 个 3x3 的卷积核、ReLU 激活函数。
  - 每个卷积层后接一个批量归一化层以加速训练并提升稳定性。
  - 最后使用一个 2x2 的最大池化层进行下采样，并跟随一个丢弃率为 0.25 的 Dropout 层以防止过拟合。

- **第二卷积块：**
  - 结构与第一块类似，但卷积核数量增加至 64 个。
  - 同样包含卷积、批量归一化、池化和丢弃率为 0.25 的 Dropout 操作。

- **第三卷积块：**
  - 结构与前两块类似，卷积核数量进一步增加至 128 个。
  - 最终通过最大池化层和丢弃率为 0.25 的 Dropout 层输出特征图。

- **展平层：**将特征图转换为一维特征向量，以供后续全连接层处理。

- **全连接部分：**
  - 第一全连接层：包含 256 个神经元，使用 ReLU 激活，并施加 L2 权重正则化（系数为 0.001）。
  - 第二全连接层：包含 128 个神经元，使用 ReLU 激活，同样施加 L2 正则化（系数为 0.001）。
  - 每个全连接层后都接有批量归一化层和丢弃率为 0.5 的 Dropout 层，以进一步增强泛化能力。

- **输出层：**一个神经元数量等于类别数（10）的全连接层，使用 Softmax 激活函数，输出每个类别的预测概率。

3.1.5 数据增强

在上面的四种算法中，我们可以引入数据增强（Data Augmentation）技术以提升模型性能。具体步骤如下：对于每个 28×28 像素的训练样本 X_i（其中 $i = 1, 2, \cdots, 60000$），首先生成一个服从均匀分布 Uniform$(0, 1)$ 的随机数 a_i，若 $a_i > 0.5$，则将该样本图像随机旋转一个角度，旋转角度服从均匀分布 Uniform$(-10°, 10°)$。随后，再生成另一个服从均匀分布 Uniform$(0, 1)$

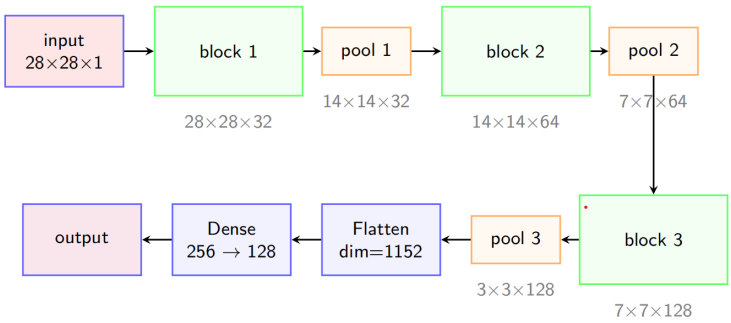


图 4: 本项目使用的 CNN 的结构

的随机数 b_i，若 $b_i > 0.5$，则将该图像在水平和垂直方向上分别随机平移，平移量服从均匀分布 $\mathrm{Uniform}(-2, 2)$ 个像素点。所有经过变换的图像均被添加至训练集中，同时保留原始图像。

从直观上看，这种方法使模型能够学习到“书写不端正”的字符与“书写端正”的字符属于同一类别，从而提升模型的识别准确率。另一方面，数据增强也有效扩充了训练数据集，起到了类似于自助采样法（bootstrap）的作用，有助于提高模型的泛化能力。

3.1.6 随机森林

随机森林（random forest）算法是一种集成学习方法，它在训练阶段构建大量决策树，并通过多数投票（用于分类任务）或平均法（用于回归任务）来整合这些树的预测结果。该方法由 Leo Breiman 于 2001 年提出，有效结合了袋装法（自助聚合）和随机特征选择的原理，以提升预测精度并控制过拟合。随机森林的根本优势在于，其通过引入两种关键随机性来创建多样化决策树的能力：训练样本的自主抽样法以及每个节点分裂时的随机特征选择。

在训练阶段，森林中的每棵树均从原始数据集中有放回地抽取，来自主抽样样本构建。对于分类问题，最终预测由所有树通过多数投票决定：$\hat{y} = \arg\max_k \sum_{t=1}^{T} \mathbb{I}(h_t(\mathbf{x}) = k)$，其中 $h_t(\mathbf{x})$ 表示第 t 棵树的预测，T 为树的总数。同时，在每棵树的节点分裂过程中，会从全部 d 个特征中随机选择一个包含 m 个特征的子集（通常对于分类任务，m 设置为 $\sqrt{d}$，满足 $m \ll d$）。这种随机特征选择降低了树之间的相关性，从而增强了模型的鲁

棒性。

关键超参数包括：树的数量（T）、每次分裂考虑的最大特征数（m）、树的最大深度以及节点分裂所需的最小样本数。这些参数用于平衡模型复杂性和计算效率。

3.1.7 残差神经网络

残差神经网络（Residual Neural Network, ResNet）是深度学习领域的一项突破性架构，由何恺明等人于 2015 年提出，旨在解决训练极深度神经网络时出现的性能退化问题。随着网络深度增加，传统架构常受梯度消失和特征复用减弱的影响，导致网络容量增大反而出现更高的训练误差。ResNet 通过引入残差学习，将学习目标重新定义为对残差映射的拟合而非直接逼近目标底层函数，从而解决了这一难题。

ResNet 的核心是实现了跳跃连接的残差块，该结构允许信息从浅层直接流向深层。形式上，残差块的输出计算为 $y = \mathcal{F}(x, \{W_i\}) + x$，其中 x 表示输入，$\mathcal{F}$ 代表通过多个加权层学习的残差映射，而加法运算使得当残差可忽略时能够实现恒等映射。这一设计使梯度能在网络中更有效地传播，缓解了梯度消失问题，从而支持训练数百甚至数千层的深度网络。

ResNet 架构主要采用两种残差块类型：用于较浅网络的 BasicBlock 和用于更深层变体的 Bottleneck 块。BasicBlock 包含两个带有批归一化和 ReLU 激活的卷积层；而 Bottleneck 块则使用 1×1 卷积进行降维，随后接 3×3 卷积和另一个 1×1 卷积进行维度恢复，显著降低了计算复杂度。

在针对 KMNIST 数据集的实现中，我们采用 ResNet-18 配置，该架构包含初始的 7×7 卷积层、最大池化层、四个依次通道数递增的 BasicBlock 阶段、全局平均池化层以及全连接分类层。ResNet18 的具体层级架构如图5所示。

3.2 性能评估

3.2.1 准确率

准确率是衡量分类模型预测性能的常用指标，表示被正确预测的标签所占的比例。对于测试数据的真实标签 $y_1, \ldots, y_n$ 和预测标签 $\hat{y}_1, \ldots, \hat{y}_n$，准确率的定义如下：

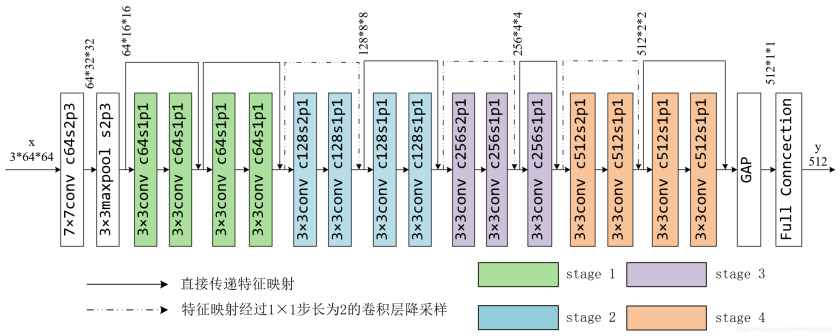


图 5: ResNet18 层级架构

$$acc = \frac{1}{n}\sum_{i=1}^{n} 1_{\{y_i=\hat{y}_i\}}$$

我们将分别评估模型在训练集和测试集上的准确率。训练准确率与测试准确率之间存在较大差异可能表明模型存在过拟合现象。

3.2.2 F_1 分数

召回率是指实际为正例的样本中被正确识别的比例。召回率的计算公式为真正例（TP）与真正例和假反例（FN）之和的比值。F_1 分数是将精确率和召回率结合为一个指标的综合评价指标。在二分类场景中，F_1 分数的计算公式为：

$$F_1 = \frac{2 \cdot \mathrm{TP}}{2 \cdot \mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$$

对于多分类问题，多类别和多标签数据集会被分解为一组二分类问题，每个类别对应一个二分类问题。然后通过对每个类别的 F_1 分数进行平均来计算整体的 F_1 分数。

3.2.3 混淆矩阵

在机器学习中，混淆矩阵（也称为错误矩阵）是一种特定的表格形式，用于可视化分类器的性能表现。相较于仅使用整体准确率，混淆矩阵提供了更详细的性能分析，能够展示模型在每个类别上的预测情况，包括真正例、假正例、真反例和假反例的数量分布。

在混淆矩阵中，行代表实际类别中的实例，而列代表预测类别中的实例。因此，对角线上的元素表示每个类别被正确分类的实例数量。混淆矩阵能够直观展示模型在每个类别上的分类性能，包括哪些类别容易被混淆，从而为进一步优化模型提供依据。

3.2.4 袋外误差

袋外误差（Out-of-Bag Error）是集成学习中常用的误差度量指标。当使用自助采样法（Bootstrap）构建训练集时，通过有放回抽样生成训练集，每个自助采样集中大约有 $1/e$（约 36.8%）的原始样本未被选中。这些未被选中的样本构成一个测试集，可用于评估基于该自助采样集训练的模型，由此计算出的误差即为袋外误差。

在集成学习中，测试集误差只能在所有模型训练完成后计算，而袋外误差在训练过程中即可获得。此外，袋外误差无需将训练数据分割为验证集和训练集，从而能够充分利用训练数据。通常，当模型超参数变化时，袋外误差与测试误差呈现出相似的变化趋势。因此，袋外误差可用于集成学习中的参数调优，为模型选择提供参考依据。

4 实验结果

在本节中，我们将评估第三节中的算法在 KMNIST 数据集上的表现，并比较各个模型之间的性能差异。前四种算法都使用了第三节中提到的数据增强技术，而实现后两种算法时并未使用该技术。

4.1 k 近邻算法

我们使用 $w(x, x_0) = \|x - x_0\|^{-1}$ 作为 k 近邻算法的权重，并考虑 $k = 1, 2, \ldots, 8$ 时，kNN 模型在 KMNIST 数据集的分类效果。我们绘制了 F1 分数随 k 变化的折线图，如图6所示。从中可以看出，F1 分数在 $k = 3$ 时取到最大值，此后 F1 分数下降的较快。

为了说明使用数据增强技术的益处，我们绘制了不使用数据增强技术和使用数据增强技术的测试集上准确率的折线对比图，如图7所示。

从中可以看出，使用数据增强技术时，测试准确率在 $k = 1, 2$ 时取到最大值，不使用时则在 $k = 2$ 时取到（分别是 92.77% 和 92.25%）。无论 k 取

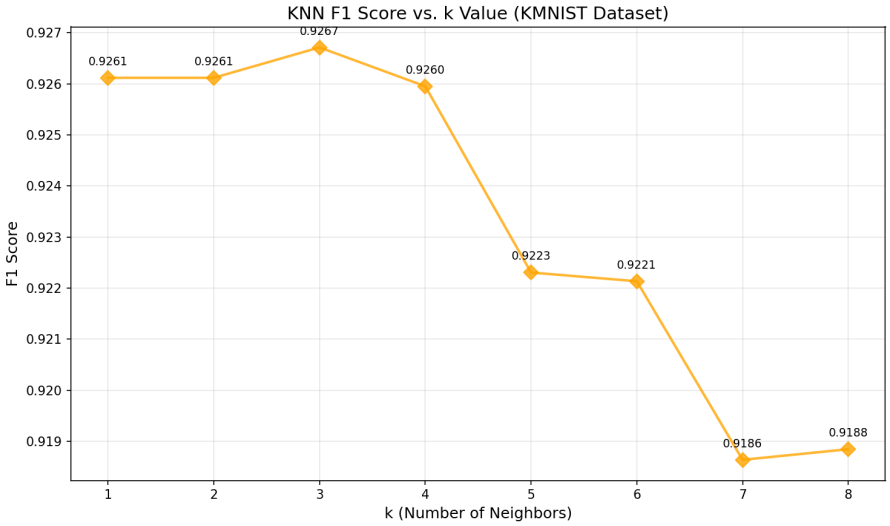


图 6: F1 Score for kNN

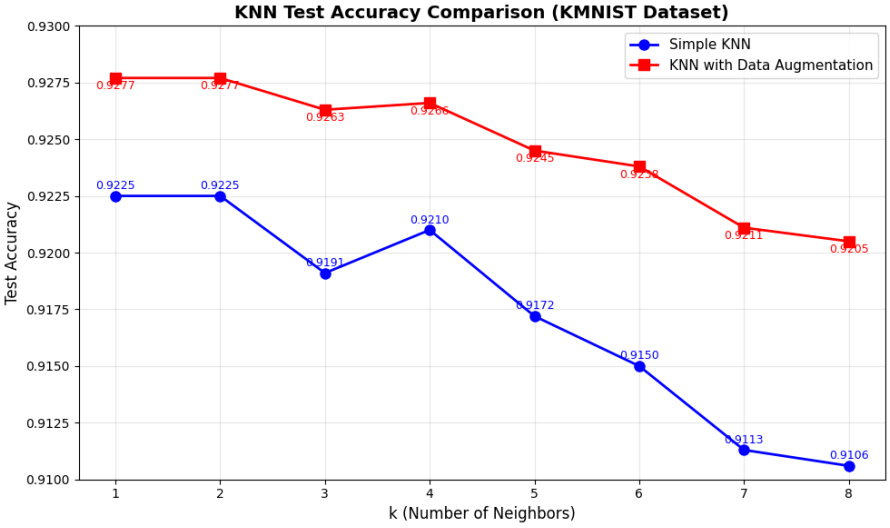


图 7: 测试误差对比

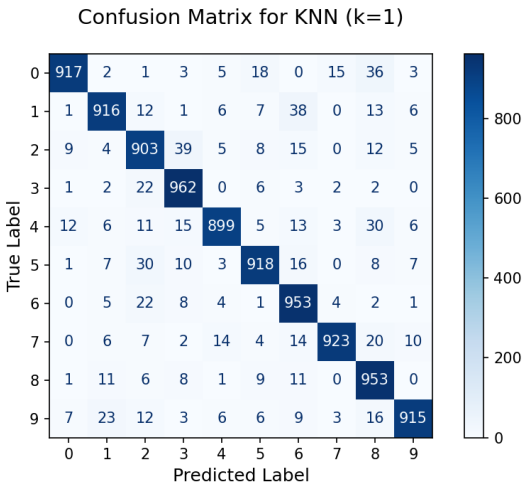


图 8: k=1 时的混淆矩阵

何值，使用数据增强技术时，测试准确率都高至少 0.5 个百分点，这说明了该技术的优越性。

我们根据准确率选取 k 值为 $k = 1$，并绘制出了 $k = 1$ 时，kNN 在测试数据集上的混淆矩阵，如图8所示。可以看出，对于所有类别，kNN 几乎都可以给出较好的预测。

4.2 随机森林

为评估随机森林在 KMNIST 数据集上的表现，我们系统地调整了每次分裂时考虑的最大特征数 m，测试范围为 m=1, 2, 4, 8, 16, 28, 40, 50, 60, 80, 100, 120, 140, 180。并绘制了测试误差和袋外误差随 m 变化的折线，如图9所示。虽然教材建议选取特征数量在 1 至 $\sqrt{784} = 28$ 之间，但我们发现两种误差都在 $m = 50$ 取到最小值，测试准确率约为 85.3%，明显低于之前讨论的 kNN 方法（92.77%）。

图10展示了 $m = 50$ 时的混淆矩阵。可以看出，整体而言随机森林的表现是远不如（随机森林的准确率约为 85%，远低于 kNN 的 92.8%），并且随机森林在标签为 7 的样本上的分类效果远不如在其他标签上的分类效果：它将较多标签为 7 的样本预测为 4。相比之下，kNN 几乎不会混淆标签为 7 和 4 的样本，这体现了随机森林的局限性。尽管如此，随机森林仍展现出训

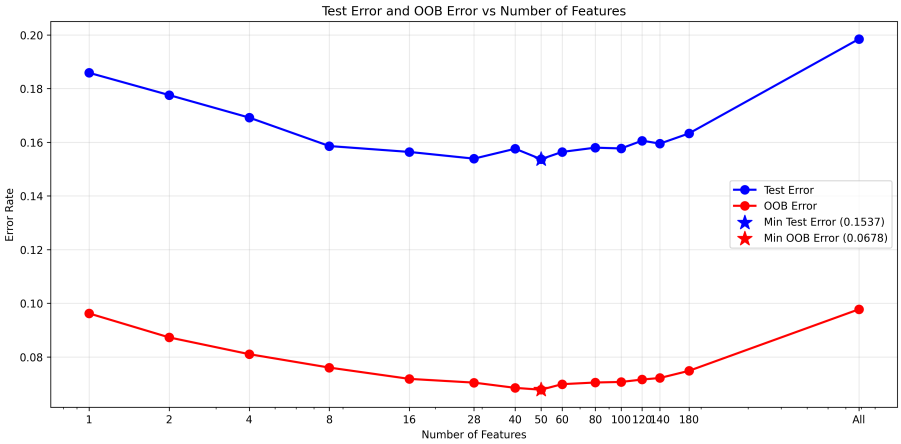


图 9: 测试误差和袋外误差

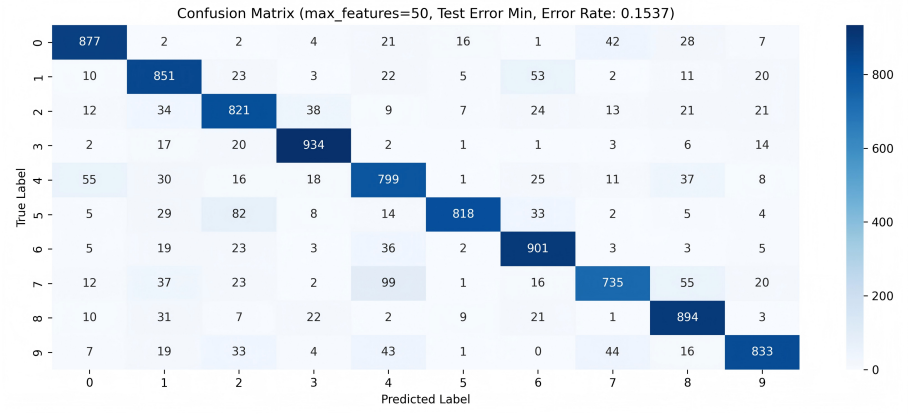


图 10: m=10 时的混淆矩阵

练速度快、无需复杂调参的优点，适用于对实时性要求较高的轻量级场景。

4.3 降维与支持向量机

我们使用 PCA 对输入进行降维。从图11可以看出，前 182 个主成分可以解释 50% 的方差，前 399 个主成分可以解释 80% 的方差，前 507 个主成分可以解释 90% 的方差。我们选取了前 50 个主成分进行分析，超参数 C 的取值为 1 至 20。图12给出了测试准确率随着 C 变化的折线。在 $C = 10$ 处，准确率取到最大值 93.87%，混淆矩阵如图12。PCA+SVM 的方法取得了比前两种算法都更高的准确率，且只在预测标签 2 的样本时容易出错（容易预测为标签 3），是一种相对准确的算法。

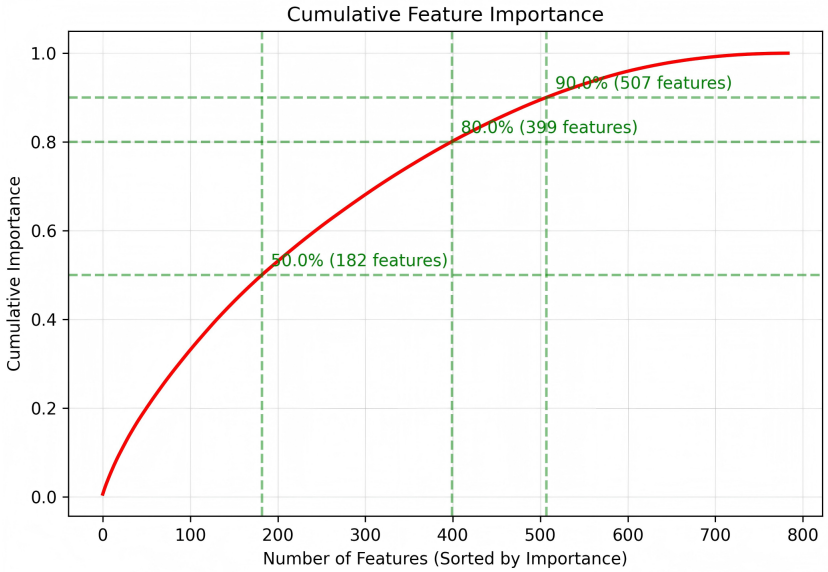


图 11: 主成分的重要性

4.4 多层感知机

我们构建的多层感知机（MLP）模型结构已在第 3.1.4 节详细说明。该模型包含三个隐藏层（512、256 和 128 个神经元），采用 ReLU 激活函数，交叉熵作为损失函数，并配合 L2 正则化与早停策略以抑制过拟合。训练过程中，我们使用 Adam 优化器，初始学习率为 0.001，并在验证集上监控损

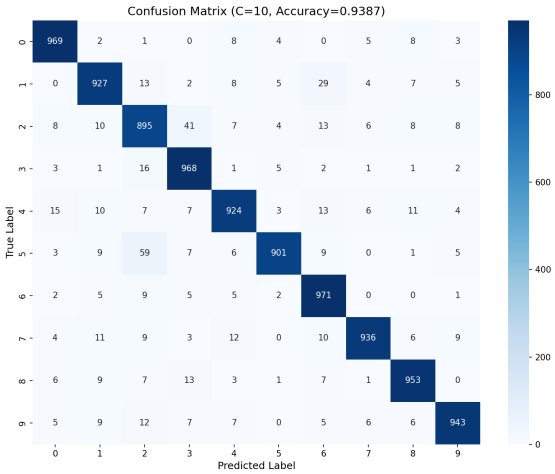


图 12: C=10 时的混淆矩阵

失变化以进行早停判断。

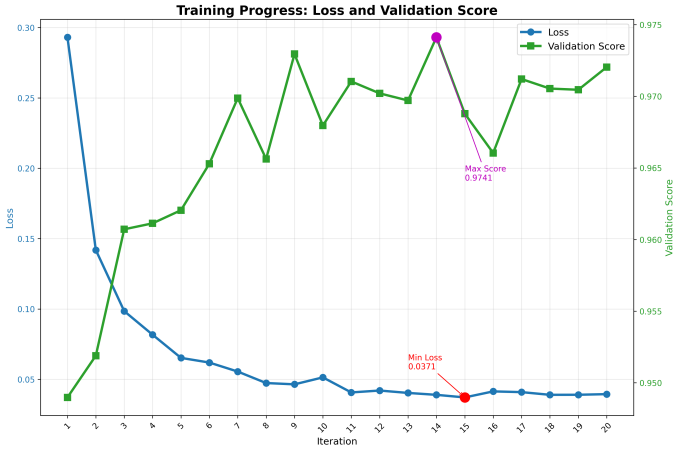


图 13: 多层感知机训练曲线

图13展示了训练过程中验证集准确率与测试集误差的变化曲线。可以看出，模型在前几个 epoch 内迅速收敛，验证集准确率在 epoch 7 附近即趋于稳定，最终维持在约 97% 的水平。最终模型的测试准确率为 92.18%。尽管该结果略低于后续使用的 CNN 与 ResNet 模型，但明显优于传统的随机森林方法，显示 MLP 在处理高维图像数据方面具有一定优势。

为深入分析模型性能，我们绘制了该模型在测试集上的混淆矩阵（14）。结果显示，MLP 在多数类别上表现良好，但在类别 2 和类别 3 之间存在较明显的混淆，这可能是由于这两类字符在笔画结构上具有一定的视觉相似性，而 MLP 作为全连接网络，在捕捉局部空间特征方面的能力有限，导致对细微差异的区分不足。

与采用数据增强的 kNN 和 SVM 相比，MLP 的准确率略低，说明在此任务上，结构简单的浅层网络仍难以充分学习 KMNIST 数据中的复杂空间变化。然而，MLP 的训练效率较高，且无需复杂的特征工程或降维步骤，在计算资源有限或需要快速原型的场景中仍具有实用价值。

总体而言，MLP 在 KMNIST 数据集上取得了可观的分类性能，验证了全连接神经网络在图像分类任务中的基础能力，同时也反映出其在处理局部结构相似性方面的局限性。

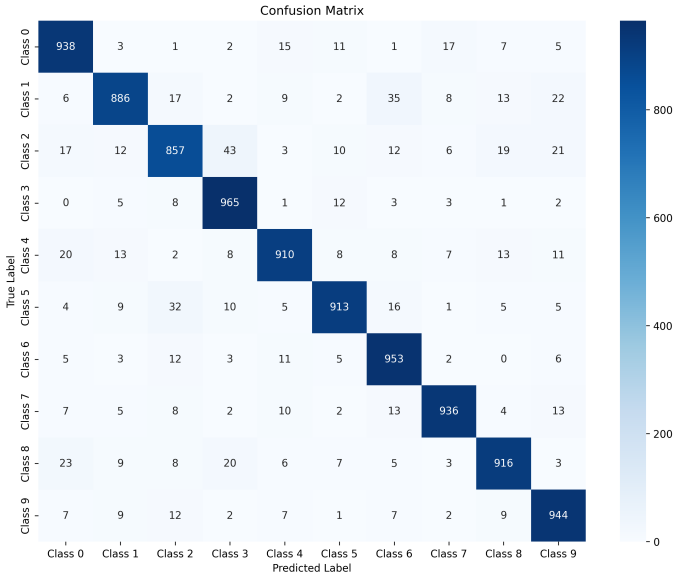


图 14: mlp 的混淆矩阵

4.5 卷积神经网络

我们构建的卷积神经网络（CNN）结构与超参数设置已在第 3.1.6 节详细阐述。该模型采用三层卷积块逐步提取特征，并结合批量归一化、Dropout

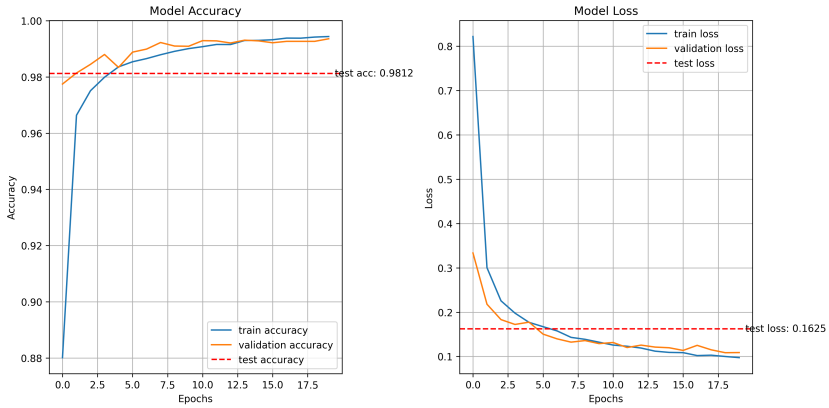


图 15: CNN 的迭代曲线

和 L2 正则化来增强泛化能力。训练过程中，我们使用 Adam 优化器，初始学习率为 0.001，并采用早停策略以预防过拟合。

训练过程的准确率与损失曲线如图15所示。从中可以看出，模型在训练初期迅速收敛，训练集准确率在 2 个 epoch 内即超过 95%。验证集准确率同步上升，且与训练集准确率差距逐渐缩小，表明模型未出现明显过拟合。最终，在测试集上达到的准确率为 98.20%，显著高于之前所有传统机器学习方法。

为进一步分析模型的表现，我们绘制了混淆矩阵（图16）。结果显示，模型在绝大多数类别上分类准确率均超过 98%，在第二类的预测上存在一定的偏差，准确率最低。同样的问题在前面的几类模型中得到的混淆矩阵中也可以观察到，说明这类字符相对难预测。

总体而言，CNN 凭借其局部感知、参数共享和层次化特征提取的能力，在 KMNIST 数据集上表现出色，验证了卷积结构在处理图像分类任务中的显著优势。

4.6 ResNet18

我们采用的 ResNet-18 结构包含四个由 BasicBlock 构成的阶段，其详细配置见第 3.1.7 节。ResNet 通过残差连接缓解了深层网络中的梯度消失问题，使其能够有效训练较深的网络结构。

训练过程中的准确率与损失曲线如图17所示。与 ResNet18 的收敛速度与 CNN 的相近，在 15 个 epoch 后逐渐稳定，最终训练准确率超过 99%。

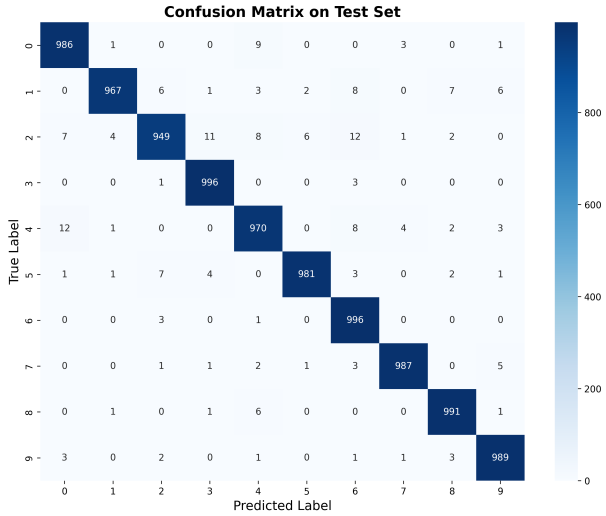


图 16: CNN 的混淆矩阵

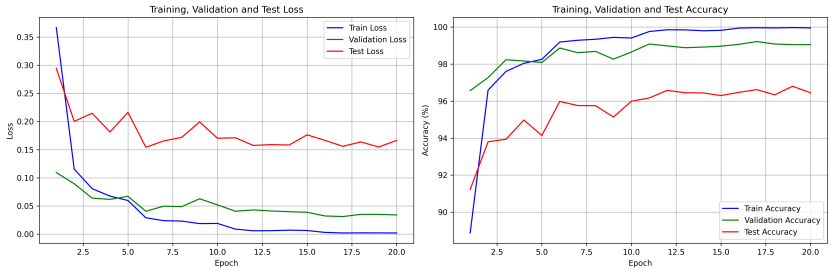


图 17: ResNet18 的迭代曲线

测试集上的最终准确率为 96.45%，略低于 CNN 模型。

图18展示了 ResNet18 在测试集上的混淆矩阵。整体来看，模型在多数类别上表现良好，但我们同样可以观察到，模型在第二类样本上的预测结果较差，只有约 91% 的准确率，这也证实了第二类样本预测的困难性。

为了探究 ResNet18 表现略低于 CNN 的原因，我们对比两者的结构差异：CNN 采用了更强的正则化策略（如更高的 Dropout 率）和更密集的全连接层，可能更适合 KMNIST 这种规模较小、类别较少的任务；而 ResNet18 的结构相对更深且参数更多，在数据量有限的情况下可能未完全发挥其表征能力。

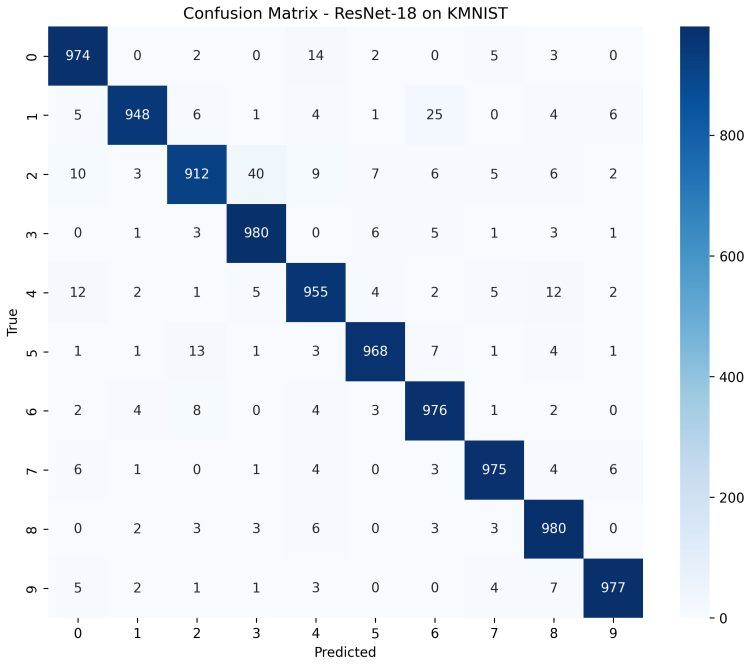


图 18: ResNet18 的混淆矩阵

5 模型性能综合比较与讨论

本项目系统评估了六种不同的机器学习与深度学习方法在 KMNIST 手写字符分类任务上的表现。各模型在测试集上的准确率对比如表1所示：

从结果可以看出，卷积神经网络（CNN）以 98.20% 的准确率显著优于其他所有模型，体现了其在图像分类任务中强大的特征提取与结构建模能力。ResNet-18 虽略低于 CNN，但仍达到 96.45%，且训练过程更为稳定，显示出残差结构在深层网络训练中的优势。

在传统机器学习方法中，支持向量机（SVM）结合 PCA 降维表现最佳（93.87%），说明核方法在处理非线性可分数据上的有效性。k 近邻与多层感知机分别达到 92.77% 与 92.18%，表现接近，但均未突破 94%。随机森林准确率最低（85.30%），其在多个类别之间的严重混淆反映了树模型对局部结构相似性的敏感度不足。

综合来看，深度学习模型（CNN、ResNet）明显优于传统方法，这主要得益于其自动学习层次化特征的能力，尤其是在处理具有空间结构、类内差异大的图像数据时表现突出。传统方法中，SVM 与 kNN 仍具竞争力，尤其适用于计算资源受限或需要高可解释性的场景。

表 1: 各个模型的测试准确率

模型	测试准确率
k 近邻	92.77%
随机森林	85.30%
PCA+SVM	93.87%
多层感知机	92.18%
卷积神经网络	98.20%
ResNet-18	96.45%

此外，数据增强对传统方法提升明显。四种模型使用数据增强前后的准确率如表2所示

本研究为 KMNIST 数据集提供了一个全面的性能基准，也为古籍字符识别在实际应用中的模型选择提供了参考：在追求极致准确率时可选用 CNN，在需要平衡性能与训练效率时 SVM 仍为可靠选择，而在资源受限环境中可考虑 kNN 或 MLP。未来工作可进一步探索更轻量化的网络结构、

表 2: 数据增强技术的效果

分类器	原始版本准确率	数据增强后准确率率
KNN	92.25%	92.77%
MLP	90.91%	92.38%
PCA+SVM	93.30%	93.87%
CNN	97.50%	98.20%

跨数据集的泛化能力以及针对“变体假名”的细粒度识别方法。

6 作者贡献说明

王浦丞同学负责实现 k 近邻，支持向量机，多层感知机和随机森林算法，并做了中期报告。吴羽迪同学负责实现卷积神经网络和残差神经网络算法，并撰写了最后的项目报告。

References

[1] Yuta Hashimoto. “The Kuzushiji Project: Developing a Mobile Learning Application for Reading Early Modern Japanese Texts”. In: 2022. URL: https://api.semanticscholar.org/CorpusID:22678262.

[2] Tarin Clanuwat et al. “Deep Learning for Classical Japanese Literature”. In: *arXiv e-prints*, arXiv:1812.01718 (Dec. 2018), arXiv:1812.01718. DOI: 10.48550/arXiv.1812.01718. arXiv: 1812.01718 [cs.CV].